

基于深度学习的牛津宠物细粒度分类实验报告

姓名：叶安 | 学号：X124306049 | GitHub 仓库

1. 任务背景与实验设置

本实验使用 Oxford-IIIT Pet 数据集完成 37 类猫狗品种的细粒度图像分类。官方 trainval 与 test 清单合并后共有 7,349 张有效图片。为保证类别比例一致，全部样本按类别进行 70%/15%/15% 分层划分，随机种子固定为 42。测试集仅在最终配置冻结后评估一次。

数据集	训练集	验证集	测试集	总样本
Oxford-IIIT Pet	5144	1102	1103	7349


模型使用 ImageNet 预训练 ResNet-18，并将最后全连接层替换为 37 类输出。输入尺寸为 224×224，训练集采用 Resize、RandomCrop 和水平翻转，验证与测试集仅使用 Resize、CenterCrop 和归一化。优化器为 AdamW，学习率为 1e-4，Weight Decay 为 1e-4，Batch Size 为 32。

配置项	设置
模型	预训练 ResNet-18，全参数微调
Baseline 损失	CrossEntropyLoss
消融损失	CrossEntropyLoss(label_smoothing=0.1)
选择标准	验证集 Top-1 Accuracy
训练设备	本地 CPU，PyTorch 2.14.0+cpu

2. 实验结果与消融分析

Baseline 共训练 15 轮，最佳结果出现在第 4 轮，之后训练集准确率继续上升而验证集表现下降，说明出现过拟合。Label Smoothing 实验使用独立脚本训练 10 轮，最佳结果出现在第 9 轮。两组使用相同数据划分、随机种子和优化配置，唯一变量为损失函数。

实验	Top-1	Top-5	Macro-F1	最佳轮次
Baseline, 验证集	92.47%	99.82%	0.9244	4
Label Smoothing 0.1, 验证集	93.19%	99.09%	0.9315	9
Label Smoothing 0.1, 测试集	92.66%	99.37%	0.9258	9



左：Baseline 训练曲线；右：Label Smoothing 训练曲线。




图 1：最佳验证集与最终测试集指标对比。

相对于 Baseline，Label Smoothing 在验证集上使 Top-1 提升约 0.73 个百分点，Macro-F1 提升约 0.71 个百分点。该提升幅度较小，且目前只完成一次随机种子实验，因此结论应限定在当前数据划分和训练配置下。

3. 错误案例与 Grad-CAM

最终模型在测试集上的主要错误集中在毛色和身体结构相近的品种。混淆矩阵显示，Egyptian_Mau 最容易被预测为 Bengal，american_pit_bull_terrier 最容易与staffordshire_bull_terrier 混淆，Siamese 则容易被预测为 Birman。

真实类别	预测类别	数量	占真实类别比例
Egyptian_Mau	Bengal	5	17.24%
american_pit_bull_terrier	staffordshire_bull_terrier	5	16.67%
Siamese	Birman	4	13.33%




图 2：37 类测试集混淆矩阵。




图 3：正确案例与错误案例 Grad-CAM。

4. AI 辅助编程说明与 Bug 复盘

AI 工具主要参与项目结构设计、数据检查、训练脚本、评估脚本和 Grad-CAM实现。关键训练由项目负责人在本地执行，实验指标均来自实际运行结果。开发过程中发现过一个真实问题：训练脚本最初直接序列化 argparse 中的 Path对象，导致保存 metrics.json 时会失败。修复方式是先通过 config_to_dict 将Path 转为字符串，再加入 JSON 写出流程。修复后重新运行并确认指标文件正常生成。

5. 局限与结论

项目完成了 37 类细粒度分类的 Baseline、单变量消融、测试集评估、混淆矩阵和Grad-CAM 分析。最终测试 Top-1 为 92.66% ，达到任务目标。主要局限是只使用单一随机种子，Label Smoothing 的提升幅度较小，且本地 CPU 训练存在明显计算成本。后续可通过多随机种子实验、更合理的数据增强和早停策略进一步验证稳定性。